

321123788

IML - 3 (22)

מס' פרק

$$\arg\max P(x|y)P(y) = 1 \quad \text{ע"פ הנתון (1)}$$

כלומר: $P(x|y=1)P(y=1) \geq P(x|y=-1)P(y=-1)$

$$P(x|y=1)P(y=1) \geq P(x|y=-1)P(y=-1)$$

$$\Downarrow$$

$$P(y=1|x)P(x) \geq P(y=-1|x)P(x)$$

$$P(x) \neq 0 \quad \Downarrow$$

$$P(y=1|x) \geq P(y=-1|x)$$

$$+ P(y=1|x) \quad \Downarrow$$

$$2 \cdot P(y=1|x) \geq P(y=-1|x) + P(y=1|x) = 1$$

$$\Downarrow$$

$$P(y=1|x) \geq \frac{1}{2}$$

כלומר:

$$\arg\max P(x|y)P(y) = 1 \Leftrightarrow P(y=1|x) \geq \frac{1}{2} \Leftrightarrow h_0(x) = 1$$

כלומר:

$$h_0(x) = \arg\max_{y \in \{+1\}} P(x|y)P(y)$$

כלומר: f היא פונקציית ההבחנה

$$h_0(x) = \arg\max_{y \in \{+1\}} f(x|y) \cdot P(y)$$

$$= \arg\max_{y \in \{+1\}} \left(\frac{1}{\sqrt{(2\pi)^d \det(\Sigma)}} \exp\left(-\frac{1}{2}(x-\mu_y)^T \Sigma^{-1}(x-\mu_y)\right) \right) P(y)$$

כלומר: Σ הוא מטריצת השונות, μ_y הוא הממוצע של y .

$$\left(\sqrt{(2\pi)^d \det(\Sigma)} \right)^{-1}$$

$$= \arg \max_{y \in \{+1, -1\}} \left(\exp \left(-\frac{1}{2} (x - \mu_y)^T \Sigma^{-1} (x - \mu_y) \right) \right) P(y)$$

לכן, נשתמש ב $\ln()$ כדי להפוך את הפונקציה לליניארית

$$= \arg \max_{y \in \{+1, -1\}} \left(\ln \left(\exp \left(-\frac{1}{2} (x - \mu_y)^T \Sigma^{-1} (x - \mu_y) \right) \right) P(y) \right)$$

$$= \arg \max_{y \in \{+1, -1\}} \left(\left(-\frac{1}{2} (x - \mu_y)^T \Sigma^{-1} (x - \mu_y) \right) + \ln P(y) \right) =$$

$$= \arg \max_{y \in \{+1, -1\}} \left(-\frac{1}{2} x^T \Sigma^{-1} x + \frac{1}{2} x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} x - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \ln P(y) \right) =$$

הטור הראשון $-\frac{1}{2} x^T \Sigma^{-1} x$ אינו תלוי ב y ולכן נשמיט אותו.
 הטור השני $\frac{1}{2} x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} x$ הוא זהה ל $x^T \Sigma^{-1} \mu_y$ כי Σ^{-1} הוא מטריצה סימטרית.

$$\mu_y^T \Sigma^{-1} x = (x^T \Sigma^{-1T} \mu_y)^T = x^T \Sigma^{-1} \mu_y$$

$$= \arg \max_{y \in \{+1, -1\}} \left(x^T \Sigma^{-1} \mu_y - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \ln P(y) \right) = \arg \max_{y \in \{+1, -1\}} \delta_y(x)$$

לכן (3)

$$S_+ = \{(x, y) \in S \mid y = +1\}, \quad S_- = \{(x, y) \in S \mid y = -1\}$$

לכן μ_y הוא הממוצע של x עבור y .

$$\mu_y = \frac{1}{|S_y|} \sum_{(x, y) \in S_y} x$$

לכן Σ הוא הממוצע של $(x - \mu_x)(x - \mu_x)^T$.

$$\Sigma = \frac{1}{|S| - 1} \sum_{(x, y) \in S} (x - \mu_x)(x - \mu_x)^T$$

כאן μ_x הוא הממוצע של x על כל S .

לכן $P(y)$ הוא ההסתברות של y .

$$P(Y = +1) = \frac{|S_+|}{|S|}, \quad P(Y = -1) = \frac{|S_-|}{|S|}$$

(4) positive -> negative -> positive
negative -> positive -> negative
negative -> positive -> negative

* false-positive -> negative -> positive

negative -> positive -> negative

negative -> positive -> negative

* false-negative -> positive -> negative

negative -> positive -> negative

negative -> positive -> negative

negative -> positive -> negative

(5) negative

$$Q = 2I_n, a = 0_{n \times 1}, A = \begin{bmatrix} -y_1 x_1 \\ \vdots \\ -y_m x_m \end{bmatrix}$$

$$d = \begin{bmatrix} y_1 b - 1 \\ \vdots \\ y_m b - 1 \end{bmatrix}$$

negative

$$\operatorname{argmin}_{v \in \mathbb{R}^n} \left(\frac{1}{2} v^T Q v + a^T v \right) = \operatorname{argmin}_{v \in \mathbb{R}^n} \left(\frac{1}{2} v^T 2I_n v + 0_{n \times 1}^T v \right) =$$

$$= \operatorname{argmin}_{v \in \mathbb{R}^n} \left(2 \cdot \frac{1}{2} \cdot v^T \cdot v + 0 \right) = \operatorname{argmin}_{v \in \mathbb{R}^n} \|v\|^2$$

$$\forall i, y_i, (w, x_i) + b \geq 1 \Leftrightarrow \begin{bmatrix} y_1 \langle w, x_1 \rangle \\ \vdots \\ y_m \langle w, x_m \rangle \end{bmatrix} \geq \begin{bmatrix} 1 - y_1 b \\ \vdots \\ 1 - y_m b \end{bmatrix} \Leftrightarrow$$

$$\Leftrightarrow \begin{bmatrix} \langle w, -y_1 x_1 \rangle \\ \vdots \\ \langle w, -y_m x_m \rangle \end{bmatrix} \leq \begin{bmatrix} -1 + y_1 b \\ \vdots \\ -1 + y_m b \end{bmatrix} \Leftrightarrow \begin{bmatrix} -y_1 x_1 \\ \vdots \\ -y_m x_m \end{bmatrix} \cdot w \leq \begin{bmatrix} -1 + y_1 b \\ \vdots \\ -1 + y_m b \end{bmatrix} \Leftrightarrow$$

$$\Leftrightarrow A w \leq d$$

(6) הוכחה: $\frac{\Delta}{2} \|w\|^2$ נראה שהסכום $\sum_{i=1}^m \epsilon_i$ הוא גבול תחתון ל- $\frac{1}{m} \sum_{i=1}^m \text{hinge}(y_i \langle w, x_i \rangle)$ עבור כל w .

אם $\epsilon_i \geq 0$ אז $y_i \langle w, x_i \rangle \leq 1 - \epsilon_i$ ולכן $\text{hinge}(y_i \langle w, x_i \rangle) \geq \epsilon_i$.


$$\text{hinge}(y_i \langle w, x_i \rangle) = \max\{0, 1 - y_i \langle w, x_i \rangle\} \geq \epsilon_i$$

אם $\epsilon_i < 0$ אז $y_i \langle w, x_i \rangle > 1 - \epsilon_i$ ולכן $\text{hinge}(y_i \langle w, x_i \rangle) = 0$.


$$\text{hinge}(y_i \langle w, x_i \rangle) = \max\{0, 1 - y_i \langle w, x_i \rangle\} \geq \epsilon_i$$

לכן $\sum_{i=1}^m \text{hinge}(y_i \langle w, x_i \rangle) \geq \sum_{i=1}^m \epsilon_i$ וזהו תוצאה ידועה.


Hyperplanes for m=5



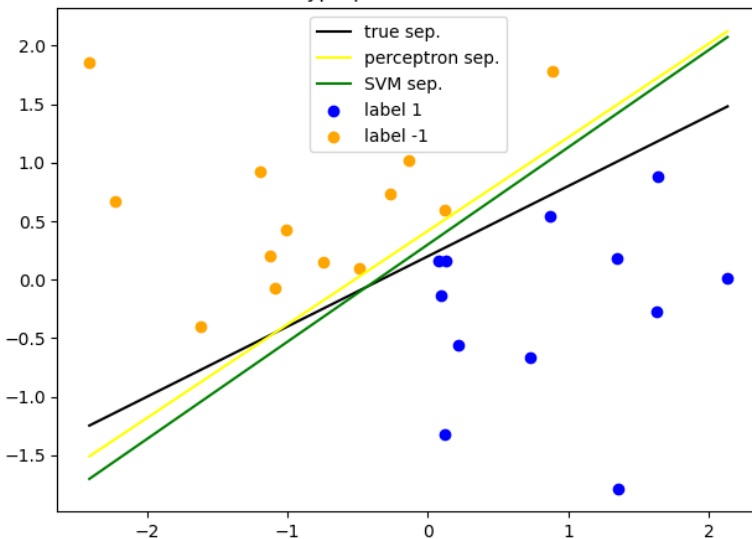
Hyperplanes for m=10




Hyperplanes for m=15



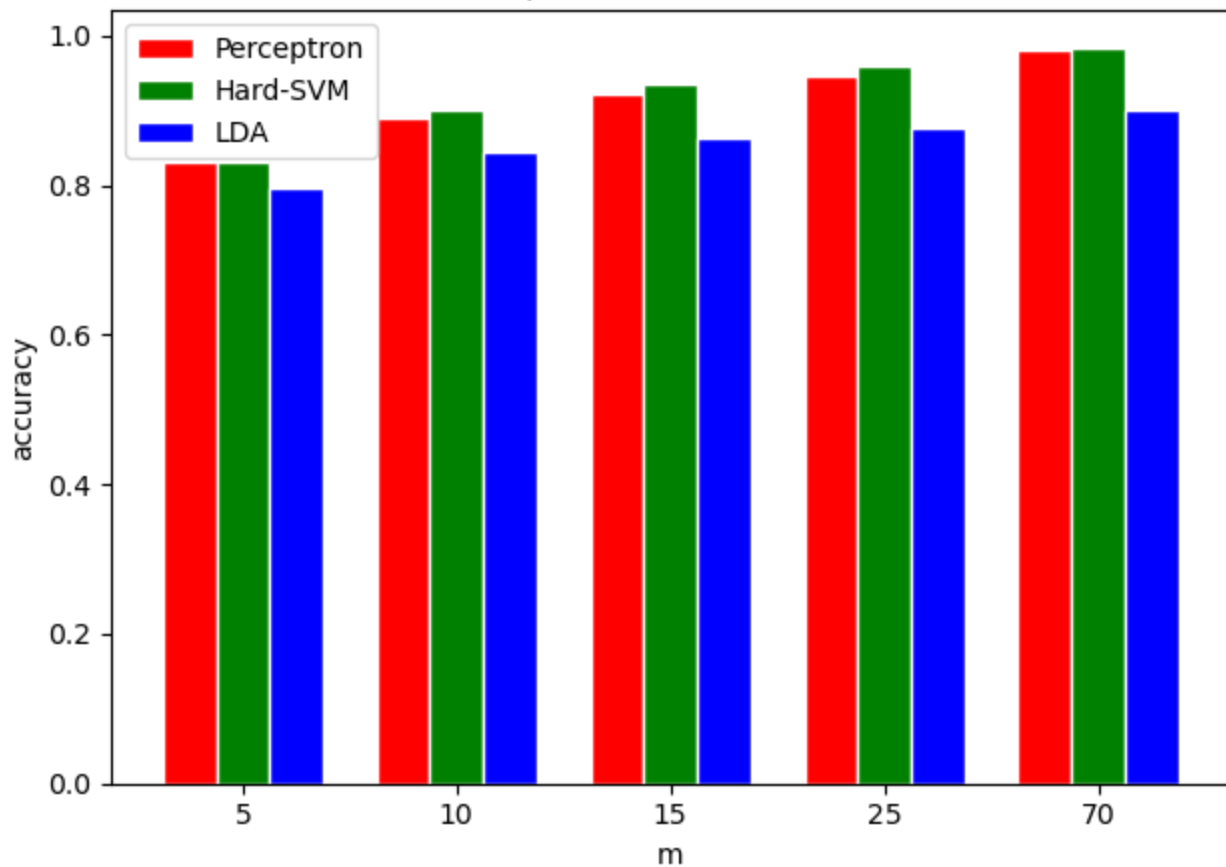
Hyperplanes for m=25



Hyperplanes for m=70









Accuracies of Perceptron, SVM and LDA as function of m



(11) תרגילי הבית הבאים: תרגיל 1.

LDA, Perceptron, Hard-SVM

אנחנו י- Hard-SVM בתצורה החדשה ביתה פיצול רפג
ע-SVM מוצא ל- hyperplane סטנדרט בצורה האופטימלית.
ל- נקודות הפרדה ביתה רגו הכפידה, פצחן ע-LDA
מחש ל- קו הפרדה האופטימלי ל- כל נקודה,
ולכן ע ר- יחד נקום אולי יקו.



(14) נתון ארבע כ מודלים הבאים:

Logistic < Tree < Soft-SVM < K-Nearest Neighbors

אשר הסידור לפי ביצועם - KNN צריך ארבע הכי גרוע

היעילות. לדוגמה קלס בוצע בוא 784, ויש מה ארבע


אחרי KNN צריך ארבע מה הכי גרוע וקוצר העתים

~~הכי גרוע~~ וזה ארבע הכי גרוע

אשר מה הכי גרוע לא מוצאם בשום פנים קוצר שמו

ולכן מודל הבאים ארבע מה הכי גרוע

Accuracies of Logistic, Soft-SVM, Tree and KNN as function of m



Logistic :

m = 50 : 0.024007797241210938
m = 100 : 0.016999244689941406
m = 300 : 0.022999048233032227
m = 500 : 0.031995534896850586

Soft-SVM :

m = 50 : 0.0569913387298584
m = 100 : 0.06499934196472168
m = 300 : 0.11614871025085449
m = 500 : 0.12100052833557129

Tree :

m = 50 : 0.01300358772277832
m = 100 : 0.012002229690551758
m = 300 : 0.016860008239746094
m = 500 : 0.031000137329101562

KNN :

m = 50 : 0.31099462509155273
m = 100 : 0.4159977436065674
m = 300 : 1.3459882736206055
m = 500 : 2.4542009830474854